

HERMES AGENT

BUILD YOUR OWN AI EMPLOYEE

จากผู้ใช้ AI → ผู้สร้าง AI Agent



Agent



Memory



Tools



Skills



Workflow



Multi-Agent



AI Employee

ลงมือทำจริง • สร้างใช้กับงานของคุณ

AI

Productivity

Future Work



AI
BETTER
WORK

อ.เฟิร์ส วัชร น้อยศรีพันธ์

Session & Memory

ทำให้ Agent จำเราได้ — จาก Context ที่หายไปทุกครั้ง
สู่ความจำที่อยู่ถาวร



ความจำที่จางหายไปทุกครั้งที่เปิด Session

เป้าหมายของวันนี้

- 01

แยกให้ออกว่า **Context**, **Session** และ **Persistent Memory** ต่างกันอย่างไร
- 02

อธิบายได้ว่าทำไม Agent จึง “ลืม” และเราควบคุมมันได้ที่จุดไหน
- 03

สร้าง User Memory และ Project Memory ให้ Agent ของตัวเองได้จริง
- 04

ปิดแล้วเปิด Agent ใหม่ แล้วมันยังทำงานต่อจากเดิมได้

DAY 2


Session
&
Memory

ชั้นความจำของ Agent

กำหนดการ 2 ชั่วโมง

20:00	● Session 3 · Context & Session	บรรยาย 30 นาที
20:30	● Workshop 3 · Session Experiment	ลงมือ 35 นาที
21:05	● Session 4 · Persistent Memory	บรรยาย 25 นาที
21:30	○ พักรับประทานอาหารว่าง	10 นาที
21:40	● Workshop 4 · Build Your AI Memory	ลงมือ 20 นาที

120 นาที



เรามาถึงไหนแล้ว

Day 1 เราได้ Agent ที่ลงมือทำงานได้ วันนี้เราเติมชั้นความจำ ก่อนจะเติม Tools ในวันที่ 3



Agent ลงมือทำได้แล้ว — วันนี้เราให้มันจำได้ ก่อนจะให้มันมีเครื่องมือในวันที่ 3

03

Context & Session

Session 3 · 20:00 – 20:30

Context คืออะไร

ทุกสิ่งที่โมเดลได้เห็นในรอบการทำงานหนึ่งครั้ง — ไม่มากไปกว่านั้น

01

Context

คำสั่ง ประวัติการคุย ไฟล์ที่แนบ และผล
จาก Tool ทั้งหมดที่ถูกส่งเข้าโมเดลใน
รอบนั้น

02

Context Window

เพดานจำนวน Token ที่ใส่ได้ เมื่อเต็ม
ของเก่าต้องออกไปเพื่อให้ของใหม่เข้า
มา

03

Conversation History

บทสนทนาที่ถูกส่งกลับเข้าไปใหม่ทุก
รอบ นี่คือเหตุผลที่ Agent ดูเหมือน “จำ”
ได้

CONTEXT WINDOW · หนึ่งรอบการทำงาน

System	Conversation History	Files	Tool Results	ว่าง
--------	----------------------	-------	--------------	------

เมื่อเต็ม — ส่วนที่เก่าที่สุดถูกดันออก และ Agent ก็ “ลืม”

ตัวอย่าง: ใน Context หนึ่งรอบมีอะไรบ้าง

คำถามสั้น ๆ หนึ่งคำถาม แต่สิ่งที่ถูกส่งเข้าโมเดลจริง ๆ คือทั้งหมดนี้

ชั้นส่วนของ Context	ตัวอย่างในงานจริง	≈ Token
คำสั่งประจำตัว	“ตอบเป็นภาษาไทย กระชับ ไม่ต้องเกริ่น”	300
Memory ที่ถูกอ่านเข้ามา	User Memory + Project Memory	800
ประวัติการคุย 20 รอบ	ทุกคำถามและคำตอบก่อนหน้านี้ในเรื่องนี้	12,000
ไฟล์ที่แนบ	sales_q3.csv · 400 แถว	6,000
ผลจาก Tool	ผลค้นหา 5 รายการที่ Agent เพิ่งดึงมา	3,000

คำถามของเราเองยาวแค่ 1 บรรทัด — ที่เหลือคือของที่ถูกแบกมาด้วย

≈ 22,100

O

โดยค่าเริ่มต้น Agent ไม่ได้เก็บอะไรไว้เลยระหว่างรอบการทำงาน สิ่งที่คุณเหมือนความจำ คือประวัติที่ถูกส่งกลับเข้าไปใหม่ทุกครั้ง เมื่อประวัตินั้นถูกตัดหรือ Session ถูกปิด สิ่งนั้นก็หายไป

Session คือขอบเขตของงาน


Session

พื้นที่ทำงานหนึ่งเรื่อง มีจุดเริ่ม มีประวัติของตัวเอง และมีจุดจบ
งานคนละเรื่องควรรออยู่คนละ Session เพื่อไม่ให้บริบทปนกัน

Session Persistence

Hermes บันทึก Session ไว้ให้กลับมาทำงานต่อได้ แต่สิ่งที่กลับมาคือ “ประวัติของงานนั้น” ไม่ใช่ความรู้เกี่ยวกับตัวเราที่ใช้ข้ามงานได้

อายุของหนึ่ง SESSION



Context Management

Context เป็นทรัพยากรจำกัด บริหารมันเหมือนบริหารพื้นที่บนโต๊ะทำงาน

O1

เริ่ม Session ใหม่เมื่อเปลี่ยนเรื่อง ดีกว่าลากบริบทเก่าติดไปทั้งหมด

O2

สรุปงานที่ยาวให้สั้นลง แล้วเก็บเฉพาะข้อสรุปไว้ใน Context

O3

อ้างอิงไฟล์แทนการวางเนื้อหาทั้งไฟล์ลงในบทสนทนา

O4

ข้อมูลที่ต้องใช้ทุกครั้ง ไม่ควรอยู่ใน Context ควรอยู่ใน Memory

ตัวอย่าง: เปลี่ยนวิธี ไม่ต้องเปลี่ยนงาน

แบบที่ทำให้ Context บวม

- × วาง sales_q3.csv ทั้ง 400 แถวลงในแชท
- × ค่อยเรื่องเดิมยาว 40 รอบจนบริบทเริ่มหาย
- × บอกชื่อ บทบาท และสไตล์ที่ชอบใหม่ทุกครั้ง

แบบที่ควบคุมได้

- ✓ “อ่านไฟล์ sales_q3.csv แล้วสรุปยอดรายเดือน”
- ✓ “สรุปข้อตกลงเป็น 5 ข้อ” แล้วเปิด Session ใหม่ด้วยสรุปนั้น
- ✓ เขียนลง User Memory ครั้งเดียว แล้วไม่ต้องบอกอีก

หลักเดียวกันทั้งสามข้อ — อย่าให้ Context แบกสิ่งที่อ้างถึงได้ หรือสิ่งที่ควรอยู่ใน Memory

W3

Session Experiment

Workshop 3 · 20:30 – 21:05

ขั้นตอนการทดลอง

- 01

สร้าง Session ใหม่
- 02


ให้ข้อมูลสำคัญกับ Agent — ชื่อ บทบาท และรูปแบบงานที่ต้องการ
- 03

ปิด Session
- 04

เปิด Session ใหม่ แล้วถามข้อมูลเดิมซ้ำ
- 05

บันทึกว่าอะไรถูกจำ และอะไรหายไป

สิ่งที่เราจะเห็น



Session ไม่ใช่ Memory

SESSION

ผูกกับงานหนึ่งเรื่อง

เกิดขึ้นเมื่อเริ่มงาน จบลงเมื่อปิดงาน ใช้ข้ามเรื่องไม่ได้

เก็บอะไร

ประวัติและสถานะของงาน

สิ่งที่คุยกันในเรื่องนั้น ขั้นตอนที่ทำไปแล้ว ผลลัพธ์ระหว่างทาง

MEMORY

ผูกกับตัวเราและโปรเจกต์

อยู่ต่อข้าม Session ถูกดึงมาใช้ได้ทุกครั้งที่ Agent เริ่มทำงาน

เก็บอะไร

ข้อเท็จจริงที่ใช้ซ้ำ

ใครคือเรา ทำงานอะไร ชอบผลลัพธ์แบบไหน โปรเจกต์มีกฎอะไร

S1

S2

S3

S4

MEMORY — อยู่ต่อข้ามทุก Session

ตัวอย่าง: ผลของการทดลอง

SESSION A

รอบแรก — เราเพิ่งบอกทุกอย่าง

เรา ผมชื่อตัน เป็น Data Engineer ตอบเป็นภาษาไทย ลั่น ๆ

Agent รับทราบครับ

เรา ช่วยร่างอีเมลแจ้งทีมเรื่องปิด pipeline ค่ะ

Agent “สวัสดีครับทีม ค่ะ pipeline จะปิดปรับปรุง
22:00–23:00 ...”

SESSION B

เปิดใหม่ — ถามคำถามเดียวกัน

เรา ช่วยร่างอีเมลแจ้งทีมเรื่องปิด pipeline ค่ะ

Agent Sure — could you tell me who the team is and
what tone you'd like?

ไม่รู้ว่าเราเป็นใคร ไม่รู้ว่าให้ตอบภาษาอะไร

ความสามารถยังอยู่ครบ — สิ่งที่หายคือบริบทของเรา

Session เก็บ “ประวัติของงานนั้น” ไว้ให้ — แต่ไม่ได้เก็บ “ความรู้เกี่ยวกับเรา” ไว้ใช้ข้ามงาน

04

Persistent Memory

Session 4 · 21:05 – 21:30

ความจำระยะ

Short-term Memory

อยู่ใน Context ของรอบนั้น เร็ว ละเอียด แต่หายไปเมื่อ Context ถูกตัดหรือ Session จบ เหมาะกับสิ่งที่ใช้เดี๋ยวนี้

Long-term Memory

ถูกเขียนลงไฟล์และถูกอ่านกลับเข้ามาทุกครั้งที่เริ่มงาน จึงอยู่ต่อข้ามวัน เหมาะกับสิ่งที่จริงเสมอ ไม่ใช่สิ่งที่จริงแค่วันนี้

สามวันทำงาน · สามรอบความจำ

SESSION 1



หายไปเมื่อจบ

SESSION 2



หายไปเมื่อจบ

SESSION 3



หายไปเมื่อจบ

LONG-TERM MEMORY — ถูกอ่านกลับเข้ามาทุกครั้งที่เริ่มงาน

Memory สามชนิด

แยกด้วยคำถามเดียว — ข้อมูลนี้จริงกับใคร กับเรา กับโปรเจกต์ หรือกับวิธีทำงาน

USER

User Memory

ตัวตนและความชอบของเรา ชื่อ บทบาท ภาษาที่ใช้ รูปแบบผลลัพธ์ที่ต้องการ ใช้ได้กับทุกโปรเจกต์

PROJECT

Project Memory

บริบทของงานหนึ่งงาน โครงสร้างไฟล์ ข้อตกลง คำศัพท์เฉพาะ และข้อจำกัดของโปรเจกต์นั้น

PROCEDURAL

Procedural Memory

วิธีทำงานที่ทำซ้ำได้ ขั้นตอนที่เราอยาก
ให้ Agent ทำเหมือนกันทุกครั้ง — ต่อย
ออกเป็น Skills ในวันที่ 3

ตัวอย่าง Memory ที่เขียนจริง

สั้น เป็นข้อ ๆ และจริงข้ามวัน — ไม่ใช่ย่อหน้าเล่าเรื่อง

USER MEMORY

- ชื่อ ต้น · Data Engineer ทีม Analytics
- ตอบเป็นภาษาไทย กระชับ ไม่ต้องเกริ่น
- โค้ดตัวอย่างขอเป็น Python 3.11
- สรุปยาว ๆ ขอ bullet ไม่เกิน 7 ข้อ

PROJECT MEMORY

- โปรเจกต์ retail-sync — ส่งข้อมูลจาก HQ ไปสาขา
- “outlet” = สาขา · “HQ” = สำนักงานใหญ่
- โค้ดอยู่ใน src/ ทดสอบอยู่ใน tests/
- ห้ามแก้ไฟล์ใน legacy/ โดยไม่ถามก่อน

PROCEDURAL MEMORY

- เวลาสรุปประชุม ให้เรียงแบบนี้เสมอ
- 1 · หัวข้อ
2 · ข้อตกลง
3 · ใครทำอะไร ภายในเมื่อไร
4 · สิ่งที่ต้อง
- ส่งเป็น Markdown ทุกครั้ง

ทั้งสามไฟล์รวมกันไม่ควรยาวกว่าหนึ่งหน้า — ยาวกว่านั้นแปลว่ามีของที่ไม่จริงข้ามวันปนอยู่

อะไรควรอยู่ใน Memory

ควรเก็บ

- ✓ ข้อเท็จจริงที่จริงเสมอ — บทบาท ทีม ภาษา
- ✓ ความชอบที่ต้องทำซ้ำ — รูปแบบไฟล์ โครงสร้างรายงาน
- ✓ ข้อตกลงของโปรเจกต์ — คำศัพท์ กฎการตั้งชื่อ
- ✓ ข้อผิดพลาดที่ไม่ต้องการให้เกิดซ้ำ

ไม่ควรเก็บ

- × รายละเอียดของงานเฉพาะรอบเดียว
- × ข้อมูลที่เปลี่ยนแปลงบ่อย เช่น สถานะงานรายวัน
- × ความลับ รหัสผ่าน และ API Key
- × ประวัติบทสนทนาทั้งหมดแบบดิบ

เขียนอย่างไรให้ Agent ใช้ได้จริง

กว้างเกินจนใช้ไม่ได้

แคบพอที่จะตรวจได้

“ชอบงานเป็นระเบียบ”



รายงานทุกฉบับขึ้นต้นด้วยสรุป 3 บรรทัด แล้วค่อยลงรายละเอียด

“ทำงานสาย data”



ดูแล pipeline ที่ดึงยอดขายสาขาเข้า warehouse ทุกคืน

“อย่าตอบยาว”



ตอบไม่เกิน 5 บรรทัด ถ้ายาวกว่านั้นให้ถามก่อนว่าจะลงลึกไหม

“ใช้ภาษาสุภาพ”



ลงท้ายด้วย ครับ · ไม่ใช่คำแสลง · ไม่เรียกผู้ใช้ว่า “คุณลูกค้า”

กฎเดียวที่ใช้ตัดสิน — อ่านแล้วบอกได้ไหมว่า Agent “ทำตาม” หรือ “ไม่ทำตาม”



Build Your AI Memory

Workshop 4 · 21:40 – 22:00

ลงมือสร้างความจำ

- 01 เขียน **User Memory** — ใครคือเรา ทำงานอะไร และอยากได้ผลลัพธ์แบบไหน
- 02 เขียน **Project Memory** — โปรเจกต์ที่เลือกมีบริบทและข้อตกลงอะไร
- 03 คัดให้เหลือเฉพาะข้อที่จริงข้ามวัน ตัดที่เหลือออก
- 04 ปิด Agent แล้วเปิดใหม่ สั่งงานเดิมโดยไม่บอกบริบทซ้ำ
- 05 ดูว่าผลลัพธ์ต่างจากก่อนมี Memory อย่างไร แล้วแก้ Memory ให้แคบลง

ผลลัพธ์

เปิด Agent ใหม่
แล้วมันยัง
รู้จักเรา

เทมเพลตเริ่มต้น — เติมช่องว่างได้เลย

เขียนให้เสร็จใน 5 นาที แล้วค่อยตัดทีหลัง สั้นเกินแก้ง่ายกว่ายาวเกิน

USER MEMORY

ผมชื่อ _____ ทำงานเป็น _____

ในทีม _____ ดูแลเรื่อง _____

ตอบเป็นภาษา _____ ความยาวประมาณ _____

รูปแบบผลลัพธ์ที่ชอบ _____

สิ่งที่ห้ามทำ _____

PROJECT MEMORY

โปรเจกต์นี้คือ _____

คำศัพท์เฉพาะ _____ แปลว่า _____

ไฟล์หรือโฟลเดอร์สำคัญ _____

ข้อตกลงของทีม _____

ข้อห้าม _____

เขียนเสร็จแล้ว ปิด Agent แล้วเปิดใหม่ — ถ้ายังต้องอธิบายตัวเองซ้ำ แปลว่า Memory ยังไม่พอ

Context ทำให้ Agent เข้าใจงานตรงหน้า
Memory ทำให้มันเข้าใจเรา

วันที่ 3 · 14 ก.ย. 2569 — Tools, Skills & MCP: เพิ่มความสามารถให้ Agent